

研究進捗報告 (2026/01/23)

1. Layer Normalization の改良

振幅正規化レイヤー `AmplitudeLayerNormalization` の正規化ロジックを改良。

従来は振幅の分布を強制的に「平均0・分散1」にしていたが、振幅（信号強度）の平均値を維持することが重要であると考え、「**振幅の平均値を保持、分散のみを1に正規化する**」手法に変更。

数式:

入力の振幅 $|z|$ 、その平均を μ 、標準偏差を σ とします。

$$z' = \left(\frac{|z| - \mu}{\sigma + \epsilon} + \mu \right) \cdot \gamma + \beta$$

- 後半で学習可能なパラメータ γ (スケール) と β (シフト) を適用し、ネットワークの表現力を確保します。

これにより、振幅が持つ物理的な意味（信号強度の強弱）を損なうことなく、統計的なバラツキを抑制できるようになります。

2. 実験結果報告 (学習失敗の観測)

学習ログ:

```
Epoch 1/300  
loss: 2637.9944 - accuracy: 0.6176  
Epoch 2/300  
loss: 8451.4023 - accuracy: 0.6703  
Epoch 3/300  
loss: 12974.8711 - accuracy: 0.6233  
...  
Epoch 12/300  
loss: 3053.1074 - accuracy: 0.5922
```

原因分析

「振幅の平均値を維持する（平均を0にしない）」という変更が、Deep Learningの学習において悪影響を与えたと考えられます。

1. **ゼロ中心分布の前提:** 多くのDeep Learningモデル（特にWeight InitializationやOptimizer）は、各層の入力が平均0周辺に分布していることを前提に設計されています。
2. **バイアスシフトの累積:** 入力の実部が正の値（振幅の平均 μ など）のまま次の層に渡されると、層が深くなるにつれて値が累積的に大きくなり（Internal Covariate Shift）、結果として出力層のロジットが巨大化。
3. **過剰な確信:** ロジットの巨大化により、モデルが極端に自信過剰（確率がほぼ1.0または0.0）な予測を行うようになり、不正解時のペナルティ（Cross Entropy Loss）が爆発的に増大したと考えられる
4. **アーキテクチャの構造:** Layer Normを繰り返す構造なので、より値が増大してしまっている。
(transformer_layers=4)

3. Split Layer Normalization (標準的な正規化)

従来手法である Split Layer Normalization（実部・虚部をそれぞれ個別に平均0・分散1に正規化）を用いた場合の結果を以下に示します。

結果: 非常に安定して学習が進んでいます。

```
Epoch 1/300
loss: 6.4599 - accuracy: 0.8051
Epoch 2/300
loss: 1.7204 - accuracy: 0.8954
...
Epoch 8/300
loss: 0.5012 - accuracy: 0.9513
```

4. Amplitude Layer Normalization (ゼロ中心化版)

「平均を0にする（標準的な正規化）」仕様に戻した Amplitude Layer Normalization での学習結果です。

結果: 正常に学習が進んでいます（Split版とほぼ同様の挙動）。

```
Epoch 1/300
loss: 6.5662 - accuracy: 0.5618
Epoch 2/300
loss: 3.1806 - accuracy: 0.7061
...
Epoch 10/300
loss: 0.4780 - accuracy: 0.8507
```