

研究進捗報告 (2026/01/26)

1. 新たな正規化手法の提案: Complex Layer Normalization

これまでの実験結果（振幅のみの正規化の失敗、Split LayerNormの成功）を踏まえ、「複素数そのものを、その統計的性質に基づいて正規化する」新たな手法を導入します。

手法の概要

振幅や実部・虚部を個別に扱うのではなく、複素数をベクトルとして捉え、その「重心（平均）」と「広がり（全分散）」を用いて正規化を行います。

数式定義

入力データ $z = x + jy$ に対して、以下の手順で正規化を行います。

1. 複素平均 (Complex Mean) の算出

複素平面上の重心を計算します。

$$\mu = E[z] = E[x] + jE[y]$$

※ 特徴量軸（チャンネル方向）に対する平均を計算します。

2. 全分散 (Total Variance) の算出

重心からの「広がり（分散）」を計算します。実部の分散と虚部の分散の和（共分散行列のトレースに相当）を使用します。

$$\sigma^2 = E[|z - \mu|^2] = \text{Var}(x) + \text{Var}(y)$$

3. 正規化 (Normalization)

複素数 z から平均 μ を引いてゼロ中心化し、全分散 σ でスケールリングします。

$$\hat{z} = \frac{z - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

4. アフィン変換 (Affine Transformation) (オプション)

学習可能なパラメータを用いて、分布を再調整します。

$$z_{out} = \gamma \cdot \hat{z} + \beta$$

- γ (Scale): 実数パラメータ (初期値 1.0)。分布の広がり进行调整。
- β (Shift): 複素数パラメータ (初期値 0.0)。中心位置进行调整。

期待される効果

- **ゼロ中心化の保証:** 複素平面上で重心が原点に揃うため、Deep Learningの学習安定性が確保されます。
- **位相関係の保持:** スカラー倍でのスケーリングとなるため、各点どうしの相対的な位相関係や形状（アスペクト比）は維持されます（Split LayerNormのように円形に歪められることはありません）。

実装においては、現在の `AmplitudeLayerNormalization` クラスをこのロジックに置き換える形で修正を行います。

2. 実験結果

指標	結果
OA (Overall Accuracy)	97.51 %
AA (Average Accuracy)	89.30 %
Kappa	96.07 %

3. 學習曲線

